



I².A²

institut d'intelligence
artificielle appliquée

i2a2.academy





Fonte: <https://www.utu.fi/en/news/news/a-brief-overview-of-kievis-approach-to-using-ai>

InsurMinds - Agentes Inteligentes com Redes Generativas

RAG (Retrieval-Augmented Generation)



Dall.e

<https://labs.openai.com/e/xYvsdZh7P3kY7OTbeD4RqdD6>

Desafio I

“Agora é pra valer”

Respostas do Desafio 1

- Textos:

- Texto 1

- Texto em latim científico, parte da obra *Philosophiæ Naturalis Principia Mathematica*
 - Autor: Sir Isaac Newton
 - Trata-se de uma parte das proposições sobre o movimento de fluidos e vórtices, onde Newton analisa matematicamente o comportamento de partículas em meios fluidos.

- Texto 2

- O texto pertence à coletânea medieval *Carmina Burana*.
 - Autor: anônimo (provavelmente vários autores, sobretudo estudantes e clérigos itinerantes — os chamados goliardos).
 - Trata-se de um conjunto de poemas em latim (e também em alemão médio e francês antigo), com temas que vão de fortuna e amor até vida boêmia e sátira social. Tornou-se famoso quando o compositor alemão Carl Orff (1895–1982) transformou-os em uma obra musical. Obra: *Carmina Burana*. Composição: 1935–1936. Estreia: 1937, Alemanha.

Respostas do Desafio 1

- Textos:

- Texto 3

- Texto em grego antigo e pertence à obra Περὶ ποιητικῆς (Poética)
 - Autor: Aristóteles
 - Data: século IV a.C.
 - É um dos tratados fundamentais da filosofia antiga sobre arte, literatura e teatro.


- Texto 4

- O texto está em chinês clássico e pertence à obra 《孫子兵法》 (A Arte da Guerra)
 - Autor: Sun Tzu (Sunzi / 孫子)
 - Data: aproximadamente século V a.C. (período dos Reinos Combatentes)
 - É um dos tratados mais influentes da história sobre estratégia militar, política e liderança. É importante até os dias atuais pois combina filosofia prática com princípios estratégicos universais aplicáveis além da guerra (negócios, política, etc.).

Respostas do Desafio 1

- Equipamento defeituoso:


Seq	V1	V2	V3	V4	V5	V6	V7	V8	V9
1	375	458	475	509	336	469	135	492	497
2	57	53	73	63	62	63	47	58	59
3	245	242	227	271	219	268	267	286	289
4	1472	1462	1582	1613	1323	1490	1494	1493	1508
5	105	103	103	118	98	101	66	118	120
6	54	62	64	55	59	63	41	59	60
7	193	184	235	207	172	223	209	156	158
8	147	122	160	139	130	152	93	101	103
9	1102	957	1137	1058	990	1098	674	878	887
10	720	566	874	628	646	706	1033	320	324
11	253	171	265	193	226	247	143	99	100
12	685	750	803	830	615	699	586	777	785
13	488	418	570	465	437	467	355	313	317
14	198	220	203	247	176	209	187	204	207
15	360	337	365	376	322	363	334	348	352
16	1374	1572	1256	1734	1235	1597	1506	1684	1701
17	156	147	175	167	138	164	139	170	172





Como Criar Nossas Soluções

Um sugestão de framework


Metodologias Cíclicas




Metodologias Cíclicas



No mundo do software




Por own work - Obra do próprio, Domínio público,
<https://commons.wikimedia.org/w/index.php?curid=1552158>




Por Lakeworks - Obra do próprio, CC BY-SA 4.0,
<https://commons.wikimedia.org/w/index.php?curid=3526338>

O modelo CRISP-DM



Ciclo de vida da IA Generativa



Ciclo de vida da IA Generativa

Definição do Problema

- Gerar definição precisa do problema de negócio
- Compreender o contexto (regras de negócio)
- Estabelecer objetivos claros
- Avaliar potencial impacto
- **Definir critérios de sucesso**

Investigação dos Dados

- Compreensão e obtenção dos dados → insumos para o contexto
- Usar RAG?
- Governança de dados

Ciclo de vida da IA Generativa

Preparação dos Dados

- Limpar, formatar e estruturar os dados
- OCR?
- Incorporar dados a um banco vetorial?
- Tratar imagens?

Desenvolvimento

- Selecionar a LLM adequada
- Treinar um novo modelo
- Reduzir o Modelo
- Fine-Tuning
- RAG
- Engenharia de prompts
- Cloud ou Edge

Ciclo de vida da IA Generativa

Avaliação

- Testes rigorosos → correção, legibilidade, desempenho e confiabilidade.
- Human-in-the-loop (HITL): Especialistas revisam e classificam as saídas da IA com base em utilidade, tom de voz e precisão factual.
- Red Teaming: Testes adversários onde se tenta "quebrar" a IA → identificar vulnerabilidades de segurança / comportamentos indesejados.

Implantação

- Configurar a infraestrutura
- Definir serviços
- Estrutura para coleta de métricas e feedback

Ciclo de Vida de IA Generativa

Monitoramento e Melhorias

- Coletar métricas e feedback.
- Avaliar necessidades de melhoria
- Identificar mudanças no ambiente (Data Drift)
- Feedback do Usuário: Monitorar sinais de uso e satisfação real para ajustar o sistema progressivamente.
- Governança de Dados: Implementar políticas para mitigar riscos éticos e legais contínuos.

Seleção do Modelo



Seleção do Modelo

Modelos pré treinados (Open AI GPT, Gemini, Llama, Mistral, etc)

Modelos personalizados



Critérios para seleção:

Modalidade – somente texto, multimodal

Tamanho – número de parâmetros

Custo

Precisão de desempenho


Janela de Contexto

Latência de inferência

Recursos suportados


Ética e viés

Aprimorar o modelo



Redução do modelo

- Distillation: Cria modelo significativamente menor, mas com desempenho e capacidades semelhantes (“aluno” e “professor”)
- Pruning: Elimina pesos ou neurônios pouco importantes preservando a precisão
- Quantization: Reduzir a precisão dos pesos e ativações do LLM.
- Knowledge Distillation: Treinar um modelo menor para imitar as saídas da LLM
- Low-rank Factorization: Decompor as matrizes de pesos do LLM em matrizes de baixa ordem.
- Compact Embeddings: Diminui a dimensionalidade dos embeddings de entrada e saída do LLM
- Parameter Sharing: Utilização da mesma matriz de pesos em múltiplas camadas de uma rede neural.



Exemplo de quantização

uid0/gemma-4-E4B-it-OBLITERATED-Q4_K_M-GGUF

like 0

Text Generation

GGUF

gemma4

abliterated

uncensored

obliteratus

refusal-removal

llama-cpp

gguf-my-repo

License: apache-2.0

Model card

Files and versions

xet

Community 1

Deploy

Use this model

Edit model card

uid0/gemma-4-E4B-it-OBLITERATED-Q4_K_M-GGUF

This model was converted to GGUF format from [OBLITERATUS/gemma-4-E4B-it-OBLITERATED](#) using llama.cpp via the ggml.ai's [GGUF-my-repo](#) space. Refer to the [original model card](#) for more details on the model.

Use with llama.cpp

Install llama.cpp through brew (works on Mac and Linux)

Downloads last month

631

GGUF

Model size

7B params

Architecture

gemma4


Hardware compatibility

4-bit

Add hardware for estimation

Q4_K_M | 5.3 GB


Fine-tuning



Fonte: <https://www.mygreatlearning.com/blog/what-is-fine-tuning/>

Fine-tuning

É o processo de **transformar** um **modelo pré treinado** em um grande e genérico dataset, adaptando-o para executar uma **tarefa nova** e mais **específica**.



Fonte: <https://www.mygreatlearning.com/blog/what-is-fine-tuning/>

Fine-tuning


Passos para realizar o ajuste fino:

- Selecionar um modelo pré treinado
- Preparar um novo dataset
- “Congelar” os pesos das camadas base
- Adicionar ou modificar as camadas de saída
- Treinar o modelo
- Avaliar os resultados


Fine-tuning x Transfer learning

Feature	Fine-tuning	Transfer Learning
Camadas treinadas	Tipicamente as camadas finais	Algumas ou todas as camadas
Dados necessários	Pouco ou moderado	Moderado
Tempo de treinamento	Baixo	Moderado
Flexibilidade	Menos flexível	Mais adaptável

Aplicações do Fine-Tuning




Desafios



Retrieval Augmented Generation (RAG)

What is RAG in AI?




The hybrid model RAG (Retrieval-Augmented Generation) bridges retrieval systems and generative models to generate responses.

Fonte: <https://www.mygreatlearning.com/blog/retrieval-augmented-generation/>

Retrieval Augmented Generation (RAG)


- RAG é uma técnica que complementa o prompt com dados externos na forma de blocos de documentos, considerando os limites de tamanho do prompt.
- Adiciona um mecanismo de busca, preenchendo a lacuna entre o conhecimento estático do modelo e dados dinâmicos do mundo real.



Fonte: <https://medium.com/fretebras-tech/langchain-construindo-um-chatpdf-com-rag-retrieval-augmented-generation-openai-e-streamlit-61125e2122de>

Componentes do RAG

Componente	Descrição
Encoder	Converte o texto da pergunta em um vetor
Retriever	Encontra os embeddings dos documentos que são similares ao embedding da pergunta
Generator	Sintetiza a saída considerando tanto o texto da pergunta quanto os trechos recuperados
Knowledge Base	Banco de dados estático ou dinâmico contendo os dados a pesquisar



Passos para utilização do RAG

- prompt = ""Você é um assistente de IA que responde as dúvidas dos usuários com bases nos documentos a baixo. Os documentos abaixo apresentam as fontes atualizadas e devem ser consideradas como verdade. Cite a fonte quando fornecer a informação.
Documentos:
{documents}
""

Passos para a utilização do RAG

- Indexação
 - Dividir os textos em “chunks”
 - Criar os embeddings
 - Armazenar em banco de dados vetorial
- Usuário submete uma questão
 - Converter a consulta em vetores (usar a mesma técnica de vetorização)
- Recuperação
 - Efetuar a pesquisa a partir da similaridade dos embeddings
 - Selecionar os top “k” resultados
- Augmentation (fusão contextual)
 - Combinar os fragmentos de texto no contexto do prompt
- Generation
 - Submeter o prompt à LLM
 - Uma resposta coerente e factual é retornada

Bancos vetoriais

- Qdrant: Opção de código aberto para armazenamento e busca eficiente de embeddings vetoriais.
- Chroma: Outra opção de código aberto entre os bancos de dados vetoriais especializados.
- Pinecone: Serviço baseado em nuvem, otimizado para busca de similaridade
- pgvector: Extensão para o PostgreSQL. Permite armazenar embeddings como strings e realizar operações vetoriais
- Elasticsearch: Pode ser usado para armazenar embeddings e também oferece busca baseada em palavras-chave (como BM25)
- OpenSearch: Similar ao Elasticsearch. Banco de dados de código aberto para RAG
- Redis: Pode ser utilizado como um banco de dados vetorial de código aberto.
- Databricks Vector Search: Plataforma de código fechado que oferece recursos para indexação e busca de vetores para aplicações RAG.



Exemplo Simples de RAG

```
from langchain import OpenAI, DocumentLoader, TextSplitter, VectorStore

# Carregar documentos
document_loader = DocumentLoader("caminho/para/seus/documentos")
documents = document_loader.load()

# Dividir os documentos em trechos menores
text_splitter = TextSplitter(chunk_size=500)
chunks = text_splitter.split(documents)

# Criar uma Vector Store com embeddings da OpenAI
vector_store = VectorStore.from_documents(chunks, embedding_model="openai-embedding")

# Função de recuperação de trechos relevantes
def retrieve_relevant_chunks(query):
    return vector_store.similarity_search(query, top_k=5)

# Função de geração de texto utilizando os trechos recuperados
def generate_response(query):
    relevant_chunks = retrieve_relevant_chunks(query)
    context = " ".join([chunk.text for chunk in relevant_chunks])
    prompt = f"Contexto: {context}\n\nPergunta: {query}\n\nResposta:"
    response = OpenAI().generate(prompt)
    return response

# Exemplo de uso
query = "Qual é a capital do Brasil?"
response = generate_response(query)
print(response)
```

Fonte: <https://hub.asimov.academy/tutorial/o-que-e-a-tecnica-de-retriever-augmented-generation-rag/>

Benefícios



Acurácia Factual: O RAG baseia suas respostas em dados externos, reduzindo alucinações da IA.




Respostas Atualizadas: Pode acessar conhecimento em tempo real, diferentemente dos LLMs tradicionais limitados a dados até o corte do pré-treinamento.



Adaptabilidade ao Domínio: Fácil adaptação a setores específicos modificando a base de conhecimento subjacente.

Aplicações do RAG

Applications of RAG in Real-World AI



Desafios do RAG



Precisão na Recuperação: Se documentos irrelevantes forem recuperados, o gerador pode produzir respostas fora do tema ou incorretas.



Complexidade Computacional: A adição de uma etapa de recuperação aumenta o tempo de inferência e o uso de recursos.




Manutenção da Base de Conhecimento: A precisão das respostas depende fortemente da qualidade e da atualização da base de conhecimento.

RAG ou Fine-Tuning?

Característica	RAG (Retrieval-Augmented Generation)	Fine-tuning (Ajuste Fino)
Modificação do LLM	Não modifica o LLM subjacente ; suplementa-o com informações recuperadas.	Ajusta os pesos e parâmetros do LLM.
Fonte de Conhecimento	Recupera informações de fontes externas (bancos de dados, documentos, web).	Os dados de treinamento adicionais são embutidos na arquitetura do modelo .
Natureza dos Dados	Mais adequado para informações que são atualizadas regularmente e dinâmicas.	Adequado para padrões que não mudam com o tempo e dados estáticos. Informações podem ficar desatualizadas e exigir retreinamento.
Custo e Recursos	Tende a ser mais econômico , pois utiliza dados existentes e reduz a necessidade de retreinamento caro.	Tradicionalmente mais caro e intensivo em computação , exigindo muitos dados e hardware de ponta.
Habilidade Técnica	Requer habilidades de codificação e arquitetura para construir sistemas de pipeline. Comparativamente mais acessível para obter feedback e solucionar problemas.	Requer experiência com NLP, aprendizado profundo, configuração de modelos e pré-processamento de dados . Geralmente mais técnico e demorado.
Transparência	Pode citar suas fontes , facilitando a rastreabilidade do output.	Menos direto para rastrear a origem de informações específicas na saída do modelo, pois o conhecimento é internalizado.
Alucinações	Ajuda a reduzir alucinações ao fundamentar as respostas em dados recuperados verificáveis.	Pode alucinar se o contexto ou os dados de treinamento forem mal interpretados.
Contexto de Dados	Permite que o LLM acesse informações domínio-específicas e atualizadas .	Ajuda o modelo a interpretar o conhecimento que já tem de forma mais refinada (e.g., nuances, terminologias).

Engenharia de Prompts




Engenharia de prompts

- Contexto
- Papel
- Expectativa
- Delimitadores
- Instruções
- Formato da resposta
- Placeholders
- Exemplos

In-context Learning	
Característica da Tarefa	Tipo de Prompt
Tarefa simples	Zero-shot
Pouca variação de saída	One-shot
Tarefa complexa com padrão desejado	Few-shot
Raciocínio, lógica ou contexto encadeado	Chain-of-Tought

Agentes



Exemplo de Assistente com Agentes

```
HERMES-AGENT
Nous Research · Messenger of the Digital Gods

Hermes Agent v0.11.0 (2026.4.23)

gemini-3.1-flash-lite-preview ·
Nous Research
/home/clszvd
Session: d7c64a25

Available Tools
browser: browser_back, browser_click, browser_console, browser_get_images, ...+6
clarify: clarify
code_execution: execute_code
cronjob: cronjob
delegation: delegate_task
file: patch, read_file, search_files, write_file
memory: memory
session_search: session_search
(and 5 more toolsets...)

Available Skills
autonomous-ai-agents: claude-code, codex, hermes-agent, opencode
creative: architecture-diagram, ascii-art, ascii-video, baoyu-comic, ...+9
data-science: jupyter-live-kernel
devops: webhook-subscriptions
email: himalaya
gaming: minecraft-modpack-server, pokemon-player
general: dogfood

> Por favor, me traga um resumo das notícias constantes no site Google News.

└─ Tool calls (1) ~12 tokens
  └─ ● Browser Navigate("https://news.google.com/home")
    └─ Completed in 2.8s

Aqui estão as principais manchetes no Google News agora:

• Visita do Rei Charles III: O Rei Charles está realizando uma visita diplomática importante, incluindo um discurso raro perante o Congresso dos EUA e encontros com Donald Trump.
• Indiciamento de James Comey: O ex-diretor do FBI, James Comey, foi indiciado novamente pelo Departamento de Justiça, em um caso que gerou ampla cobertura na imprensa norte-americana (CNN, NYT, Fox News).

Essas são as notícias de maior destaque neste momento. Se desejar detalhes sobre algum desses tópicos ou outros assuntos específicos, é só pedir!

- ready | gemini-3.1-flash-lite-preview | 0/1m | [ ] 0% | 2m 4s | voice off
>
```




PRACTICE
MAKES
PERFECT



Dall.e

<https://labs.openai.com/e/xYvsdZh7P3kY7OTbeD4RqdD6>

Desafio II

“Vamos conversar?”

O que fazer?



Vamos desenvolver um **ChatBot de Atendimento.**



O que fazer: Criar um chatbot ou assistente virtual baseado em IA para automatizar o atendimento ao segurado, respondendo a perguntas frequentes e direcionando solicitações.



Este desafio visa otimizar a interação com o cliente, proporcionando respostas rápidas e eficientes, liberando a equipe humana para casos mais complexos.



Ações necessárias: Mapear e categorizar as perguntas frequentes (FAQs) dos segurados.



Estruturar fluxos de atendimento conversacionais para diferentes tipos de consultas.

O que fazer?



Treinar o modelo de IA com dados históricos de interações e FAQs para melhorar a compreensão e as respostas.



Bases de dados para treinamento: Datasets de FAQs de seguros (Kaggle): Plataformas como Kaggle frequentemente hospedam conjuntos de dados de perguntas e respostas que podem ser adaptados.



Documentação pública de processos: Manuais, termos e condições de apólices podem ser usados para extrair informações e treinar o chatbot.



LLMs (Large Language Models): Podem ser usados para gerar respostas mais naturais e compreender intenções complexas.



RAG para enriquecer o contexto das respostas.

O que fazer?



Opcional: Obter histórico de tickets de suporte (anonimizado) - Dados internos de atendimento (se disponíveis e anonimizados) são a fonte mais rica para treinamento.



Opcional: Integrar o chatbot com sistemas de CRM (Customer Relationship Management) para acesso a informações do segurado e personalização do atendimento.

Como fazer?



Criem um grupo com até 5 integrantes.

A criação dos grupos é espontânea. Troquem mensagens entre si. Estes grupos não serão necessariamente os mesmos grupos que avançarão para a segunda parte do curso.



Sugere-se que nos grupos haja pelo menos 1 pessoa que tenha conhecimento do ramo de seguros e pelo menos 1 com maior fluência em tecnologia.



Criem um nome para o grupo e elejam um representante.



Informem à equipe do I2A2, através do e-mail sac@i2a2.academy

O nome do grupo.
Quem é o representante
Quem são os componentes do grupo



Reúnam-se, definam os passos que devem ser executados e distribuam as tarefas.

Como entregar?

- **Atenção.** Esta atividade **É ELIMINATÓRIA.**
- Envie um e-mail para o endereço challenges@i2a2.academy com o assunto “**InsurMinds - Atividade obrigatória 2**”. O assunto do e-mail é fundamental para conseguirmos localizá-lo. Escreva exatamente o que pedimos acima.
- O e-mail deve ser enviado pelo representante do grupo. Mas ele deve enviar uma cópia para todos os demais integrantes do grupo. Isto inclusive funcionará como um **protocolo de entrega**.
- No corpo do e-mail deve constar:
 - 1. Nome do Grupo
 - 2. Lista dos integrantes do grupo com Nome, e-mail e celular.
 - 3. Caso exista uma versão executável do ChatBot, incluir o link para acesso
- Anexar no e-mail:
 - Todos os artefatos gerados (códigos fonte, documentos, bases de dados, diagramas, etc.)
 - O relatório em formato PDF descrevendo o experimento
 - As evidências da execução do ChatBot

Como entregar?

- Os e-mails com as respostas serão aceitas até **29/05/2026 às 23h59.**
- Grupos que não efetuarem sua entrega até o limite estabelecido, serão considerados como desistentes em caráter definitivo e irreversível.
- Até o dia 01/06/2026 os alunos aptos para a terceira fase do curso receberão um e-mail com o link do novo grupo de WhatsApp. Fiquem atentos!
- Lembrem-se que vocês terão todo o mês de maio para desenvolver a atividade. Não deixem para a última hora.

Perguntas?





Obrigado!

i2a2.academy



+55 16 99213-2650



celso@i2a2.academy



/in/celso-augusto-morato-azevedo